

Modele regresji i ich zastosowania

Lista 1 i 2

Jan Solarz
243889

18 marca 2021

Spis treści

1	Zadania laboratoryjne	1
1.1	Zadanie 1	1
1.2	Zadanie 2	4
1.3	Zadanie 3	5
1.4	Zadanie 4	6
1.5	Zadanie 5	7
1.6	Zadanie 6	8
1.7	Zadanie 7	8
1.8	Zadanie 8	8
1.9	Zadanie 9	11
1.10	Zadanie 10	13
2	Zadania teoretyczne	17

1 Zadania laboratoryjne

1.1 Zadanie 1

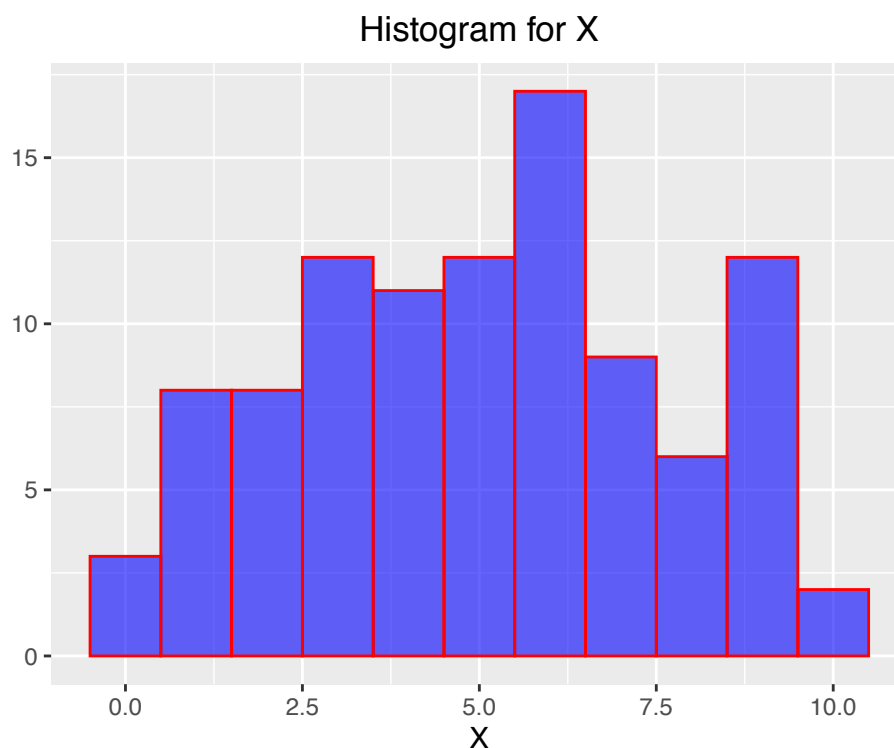
Analizy zaczynamy od zapoznania się z plikiem zawierającym zmienne x i y w stu rekordach.

```
lab1 <- read.delim2("~/Downloads/lab1.txt")
library(ggplot2)
attach(lab1)

my.summary <- function(x)
{
  wskazniki<- c(min(x),quantile(x,0.25), median(x), mean(x), quantile(x,0.75), max(x), c
  names(wskazniki) <- c("minimum", "Q1", "mediana", "średnia", "Q3", "maksimum","odch_st
  return(wskazniki)
}
apply(lab1 , function(x) my.summary(as.numeric(x)) )
```


```
##           x           y
## minimum    0.105200  0.231600
## Q1         3.016625  7.329675
## mediana    5.235750 11.408750
## średnia    5.020899 11.135093
## Q3         6.866625 14.966675
## maksimum    9.765800 21.009400
## odch_stand. 2.589414  5.367752
## wariancja   6.705065 28.812766
```

```
par(mfrow=c(1,2))
qplot(x,
      binwidth = 1,
      main = "Histogram for X",
      xlab = "X",
      fill=I("blue"),
      col=I("red"),
      alpha=I(.6))+
  theme(plot.title = element_text(hjust = 0.5))
```



```
qplot(y,
      binwidth = 1,
      main = "Histogram for Y",
      xlab = "Y",
      fill=I("green"),
      col=I("red"),
```


```
alpha=I(.6))+
theme(plot.title = element_text(hjust = 0.5))
```



```
par(mfrow=c(1,1))
a = data.frame(group = "X", value = x)
b = data.frame(group = "Y", value = y)

plot.data = rbind(a,b)

ggplot(plot.data, aes(x=group, y=value, fill=group)) +
  geom_boxplot()
```




Rysunek 1: Boxplot dla x i y

Wskaźniki i wykorzystane wykresy pokazują że dane z y są dużo bardziej zróżnicowane od x . Mamy rozstęp danych odpowiednio 10 i 21 jednostek. Histogramy i boxploty wskazują na wyraźne grupowanie się liczb w x w mniejszą ilość klas niż w y .

1.2 Zadanie 2

```
ggplot(lab1, aes(x = x, y = y)) +
  geom_point(shape=18, color="blue")+
  geom_smooth(method=lm, linetype="dashed",
              color="darkred", fill="blue")
```

```
## 'geom_smooth()' using formula 'y ~ x'
```



Rysunek 2: Wykres rozproszenia x i y

```
cor(x,y)
```

```
## [1] 0.9853143
```

Korelacja między x i y jest wysoka i wynosi 0.985. Chmura punktów ma zdecydowanie w przybliżeniu liniowy charakter. W związku z tym możemy wykorzystać dany poniżej model regresji liniowej do opisanie zależności jakie występują między x i y

$$y = \beta_0 + \beta_1 \cdot x + \epsilon \quad (1)$$

1.3 Zadanie 3

```
model <- lm( y ~ x, data=lab1)
```

```
names(model)
```

```
## [1] "coefficients" "residuals"      "effects"        "rank"
## [5] "fitted.values" "assign"         "qr"            "df.residual"
## [9] "xlevels"      "call"          "terms"         "model"
```

```
model.opis <- summary(model)
```

```
names(model.opis)
```

```
## [1] "call"          "terms"         "residuals"     "coefficients"
## [5] "aliases"       "sigma"         "df"            "r.squared"
## [9] "adj.r.squared" "fstatistic"    "cov.unscaled"
```

```

model.opis

##
## Call:
## lm(formula = y ~ x, data = lab1)
##
## Residuals:
##      Min       1Q   Median       3Q      Max
## -2.00391 -0.68670  0.05062  0.55173  2.01107
##
## Coefficients:
##              Estimate Std. Error t value Pr(>|t|)
## (Intercept)  0.87982     0.20178   4.36 3.21e-05 ***
## x            2.04252     0.03576  57.12 < 2e-16 ***
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Residual standard error: 0.9212 on 98 degrees of freedom
## Multiple R-squared:  0.9708, Adjusted R-squared:  0.9705
## F-statistic: 3263 on 1 and 98 DF,  p-value: < 2.2e-16

beta_0<-model.opis$coefficients[1]
beta_1<-model.opis$coefficients[2]

#beta_0 <- cor(y, x) * sd(y) / sd(x)
#beta_1 <- mean(y) - beta1 * mean(x)
#betas<-rbind(c(beta0, beta1), coef(lm(y ~ x)))

```

Wartości estymatorów najmniejszych kwadratów parametrów dla β_0 i β_1 wynoszą $\hat{\beta}_0 = 0.8798193$, $\hat{\beta}_1 = 2.042517$

1.4 Zadanie 4

```

n=100
for (i in x) {
  for (j in y) {
    z1 = (y-beta_0-beta_1*x)^2
  }
}
sigma2 = sum(z1)/(n-2)
sigma2

## [1] 0.8486302

```

Znajdujemy wartość estymatora $\hat{\sigma}^2$ parametru σ^2 , który jest równy 0.8486302. Korzystamy z prognozowanej przez model zmiennej objaśnianej y :

$$\hat{y}_i = \hat{\beta}_0 + \hat{\beta}_1 \cdot x_i \quad (2)$$

1.5 Zadanie 5

```
attach(lab1)

## The following objects are masked from lab1 (pos = 3):
##
##      x, y

x<-x[1:100,]

## Error in x[1:100, ]: niepoprawna liczba wymiarów

mean(x)

## [1] 5.020899

for (i in x){
  x_1 = (x-mean(x))^2
}
SE2=sigma2/sum(x_1)
SE2

## [1] 0.00127844

T1 = beta_1/sqrt(SE2)
abs(T1) >= qt(p=0.99/2,df = n-2)*sqrt(SE2)

## [1] TRUE

model.opis

##
## Call:
## lm(formula = y ~ x, data = lab1)
##
## Residuals:
##      Min       1Q   Median       3Q      Max
## -2.00391 -0.68670  0.05062  0.55173  2.01107
##
## Coefficients:
##              Estimate Std. Error t value Pr(>|t|)
## (Intercept)  0.87982     0.20178   4.36 3.21e-05 ***
## x            2.04252     0.03576  57.12 < 2e-16 ***
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Residual standard error: 0.9212 on 98 degrees of freedom
## Multiple R-squared:  0.9708, Adjusted R-squared:  0.9705
## F-statistic: 3263 on 1 and 98 DF, p-value: < 2.2e-16
```

- Poprzez oszacowanie statystyki, która spełnia nierówność z treści zadania możemy odrzucić hipotezę zerową.
- p-wartość jest bardzo niska, mniejsza od $2.2e-16$
- Przyjęty model regresji liniowej ma sens

1.6 Zadanie 6

```
beta_range = c(beta_1,beta_1) + c((qt(p=0.99/2,df = n-2)*sqrt(SE2)), -qt(p=0.99/2,df = n-2)*sqrt(SE2))
beta_range

## [1] 2.042068 2.042967
```

Przedział ufności dla β_1 na poziomie ufności 0.99 wynosi 2.042068, 2.042967. Jest on bardzo wąski.

1.7 Zadanie 7

```
x0=1
Y_0= beta_0+beta_1*x0
Y_0

## [1] 2.922337

SEE2=sigma2*(1+1/n+(x0-mean(x))/sum(x_1))

beta_range2 = c(Y_0,Y_0) + c((qt(p=0.99/2,df = n-2)*sqrt(SEE2)), -qt(p=0.99/2,df = n-2)*sqrt(SEE2))
beta_range2

## [1] 2.910738 2.933935
```

- Prognozowana przez model wartość wynosi 2.922337
- Przedział ufności na poziomie ufności 0.99 wynosi 2.910738, 2.933935

1.8 Zadanie 8

```
y_daszek= beta_0+beta_1*x

e=y-y_daszek


qplot(e,
      binwidth = 0.3,
      main = "Histogram for Residuals",
```



```

xlab = "e",
fill=I("blue"),
col=I("red"),
alpha=I(.6))+
theme(plot.title = element_text(hjust = 0.5))


```



```


qqplot(seq(1,100),e, col="green")

```



```
ggplot(lab1,aes(x = x, y = e)) +
  geom_point(shape=18, color="blue")+
  geom_smooth(method=lm, linetype="dashed",
              color="darkred", fill="blue")
```


'geom_smooth()' using formula 'y ~ x'



```
data8<-cbind(y_daszek,e)
```

```
ggplot(lab1,aes(x = y_daszek, y = e)) +
  geom_point(shape=18, color="blue")+
  geom_smooth(method=lm, linetype="dashed",
              color="darkred", fill="blue")
```

'geom_smooth()' using formula 'y ~ x'



```
cor(e,y_daszek)

## [1] 9.100764e-16

cor(e,x)

## [1] 9.376956e-16
```

Nie ma korelacji między x i e oraz między $y.daszek$ i e , korelacja jest równa prawie zero, stąd model regresji liniowej poprawnie opisuje zależność między zmiennymi x i y .

1.9 Zadanie 9

```
lab1[lab1 == 14.864] <- 1486.4
attach(lab1)

## The following objects are masked from lab1 (pos = 3):
##
## x, y
## The following objects are masked from lab1 (pos = 4):
##
## x, y

model <- lm( y ~ x, data=lab1)
names(model)

## [1] "coefficients" "residuals" "effects" "rank"
## [5] "fitted.values" "assign" "qr" "df.residual"
## [9] "xlevels" "call" "terms" "model"
```

```

model.opis <- summary(model)
names(model.opis)

## [1] "call"          "terms"          "residuals"      "coefficients"
## [5] "aliased"        "sigma"          "df"             "r.squared"
## [9] "adj.r.squared" "fstatistic"     "cov.unscaled"

model.opis

##
## Call:
## lm(formula = y ~ x, data = lab1)
##
## Residuals:
##      Min       1Q   Median       3Q      Max
## -35.67  -22.36  -15.41   -5.92  1448.52
##
## Coefficients:
##              Estimate Std. Error t value Pr(>|t|)
## (Intercept)   -5.706      32.302  -0.177   0.860
## x              6.285       5.724   1.098   0.275
##
## Residual standard error: 147.5 on 98 degrees of freedom
## Multiple R-squared:  0.01215, Adjusted R-squared:  0.002073
## F-statistic: 1.206 on 1 and 98 DF,  p-value: 0.2749

model.opis$coefficients[1]

## [1] -5.70636

model.opis$coefficients[2]

## [1] 6.285092


cor(x,y)

## [1] 0.1102418

ggplot(lab1, aes(x = x, y = y)) +
  geom_point(shape=18, color="blue")+
  geom_smooth(method=lm, linetype="dashed",
              color="darkred", fill="blue")

## 'geom_smooth()' using formula 'y ~ x'

```



Po modyfikacji jednej zmiennej korelacja estymatory się diametralnie zmieniły, zarówno korelacja. Obserwacja jest odsająca (odbiega od trendu) oraz wpływowa (wpływa na wartości estymatorów i korelacji)

1.10 Zadanie 10

```
alpha=0.1
beta_1=1
beta_2=2
a<-runif(100,0,1)
b<-rnorm(100,0,0.1)
y_i=beta_1+beta_2*a+b
y_i
```


##	[1]	1.1991891	0.9575195	0.9792601	1.4030683	1.0042272	1.3236233	2.1113730
##	[8]	1.0982938	2.2958221	1.1840066	1.5596475	1.1894853	2.5536544	1.6839744
##	[15]	1.6129790	1.1907880	2.4314429	1.9911667	1.9013027	0.8912648	2.2960319
##	[22]	1.3845578	1.5316918	1.8678440	0.9608431	1.7894532	3.0771578	2.2216984
##	[29]	0.9688864	2.0694693	1.4300036	2.4164225	1.3570466	2.4333502	1.3942233
##	[36]	2.0876357	2.2700162	1.8631924	2.2336966	2.5029511	1.5000343	1.7694704
##	[43]	0.9142646	1.2540368	2.0963761	1.4249189	1.4757915	2.5360531	1.2765705
##	[50]	1.9915369	1.0364221	1.8647850	2.2136018	1.3559727	1.2822449	1.3398075
##	[57]	1.7509016	2.2077012	1.6363954	1.3319987	1.1132891	2.0367808	2.3116341
##	[64]	2.9600560	1.0573411	1.7580967	2.8568143	2.3617091	1.6599640	1.6259621
##	[71]	1.1558383	1.9650424	2.6318513	1.4458857	1.5097794	1.8585716	1.3799444
##	[78]	1.7704001	2.3302458	2.0453914	2.4530366	2.6115577	1.3513294	1.5621545
##	[85]	1.9087573	2.6998868	2.0984862	1.1099518	1.6565288	2.2820573	2.7584640

```
## [92] 1.9885583 1.9819144 1.0299330 1.2217359 2.8689305 1.1100520 1.6213341
## [99] 2.4100528 0.9668315
```

```
#b
```

```
ggplot(lab1, aes(x = a, y = y_i)) +
  geom_point(shape=18, color="blue")+
  geom_smooth(method=lm, linetype="dashed",
              color="darkred", fill="blue")
```

```
## 'geom_smooth()' using formula 'y ~ x'
```



```
#c
```

```
model <- lm( y_i ~ a)
model.opis <- summary(model)
model.opis$coefficients[1]
```

```
## [1] 0.9981244
```

```
model.opis$coefficients[2]
```

```
## [1] 2.000613
```

```
model.opis$r.squared
```

```
## [1] 0.9698184
```

```
#wartości parametrów są bardzo przybliżone
```

```
#d
```

```
b1<-rnorm(100,0,0.5)
```


```
b2<-rnorm(100,0,1)
```

```
y_i_1=beta_1+beta_2*a+b1
```

```
y_i_2=beta_1+beta_2*a+b2
```


```
ggplot(lab1, aes(x = a, y = y_i_1)) +  
  geom_point(shape=18, color="blue")+  
  geom_smooth(method=lm, linetype="dashed",  
              color="darkred", fill="blue")
```

```
## 'geom_smooth()' using formula 'y ~ x'
```



```
ggplot(lab1, aes(x = a, y = y_i_2)) +  
  geom_point(shape=18, color="blue")+  
  geom_smooth(method=lm, linetype="dashed",  
              color="darkred", fill="blue")
```

```
## 'geom_smooth()' using formula 'y ~ x'
```



```
model <- lm( y_i_1 ~ a)
model.opis <- summary(model)
model.opis$coefficients[1]
```

```
## [1] 1.152889
```

```
model.opis$coefficients[2]
```

```
## [1] 1.948239
```

```
model.opis$r.squared
```

```
## [1] 0.5595151
```

```
model <- lm( y_i_2 ~ a)
model.opis <- summary(model)
model.opis$coefficients[1]
```

```
## [1] 1.277037
```

```
model.opis$coefficients[2]
```

```
## [1] 1.678628
```

```
model.opis$r.squared
```

```
## [1] 0.2074275
```

- Tak, chmura ma charakter liniowy

- Estymatory najmniejszych kwadratów wynoszą odpowiednio 1.035504 i 1.950445, są więc zbliżone do $\beta_0=1$ i $\beta_1=2$
- Zdecydowanie gdy rośnie sigma precyzja estymatorów maleje.
- 0.9729966 0.4788748 0.2437685 - wzrost R^2 wraz ze wzrostem sigmy.

2 Zadania teoretyczne

Zadania teoretyczne

2.1

$$S(\beta_0, \beta_1) = \sum_{i=1}^n (y_i - \beta_0 + \beta_1 x_i)^2$$

$$(\hat{\beta}_0, \hat{\beta}_1) = \arg \min_{(\beta_0, \beta_1)} [(y_i - \beta_0 - \beta_1 x_i)^2]$$

rozr. problemu minimalizacyjnego

Liwyng pochodne względem $S(\beta_0, \beta_1)$ w $(\hat{\beta}_0, \hat{\beta}_1)$, gdzie się zerują. ($S(\beta_0, \beta_1)$ jest wypukła - wartości najm. osiąga w $(\hat{\beta}_0, \hat{\beta}_1)$).

$$\frac{\partial S(\hat{\beta}_0, \hat{\beta}_1)}{\partial \hat{\beta}_0} = \frac{\partial (\sum_{i=1}^n (y_i^2 - 2y_i \hat{\beta}_0 - 2y_i x_i \hat{\beta}_1 + \hat{\beta}_0^2 + 2\hat{\beta}_0 \hat{\beta}_1 x_i + \hat{\beta}_1^2 x_i^2))}{\partial \hat{\beta}_0}$$

$$= -2 \sum_{i=1}^n (y_i - \hat{\beta}_0 - \hat{\beta}_1 x_i) = 0$$

$$\frac{\partial S(\hat{\beta}_0, \hat{\beta}_1)}{\partial \hat{\beta}_1} = -2 \sum_{i=1}^n (y_i x_i - \hat{\beta}_0 x_i - \hat{\beta}_1 x_i^2) =$$

$$= -2 \sum_{i=1}^n (y_i x_i - \hat{\beta}_0 x_i - \hat{\beta}_1 x_i^2) = 0$$

Mały

$$\begin{cases} -2 \sum_{i=1}^n y_i + 2n\hat{\beta}_0 + 2\hat{\beta}_1 \sum_{i=1}^n x_i = 0 \\ -2 \sum_{i=1}^n x_i y_i + 2\hat{\beta}_0 \sum_{i=1}^n x_i + 2\hat{\beta}_1 \sum_{i=1}^n x_i^2 = 0 \end{cases}$$

$$\begin{cases} \sum_{i=1}^n x_i = \bar{x} \\ \sum_{i=1}^n y_i = \bar{y} \end{cases}$$

$$\begin{cases} \hat{\beta}_0 = \frac{\sum_{i=1}^n y_i - \hat{\beta}_1 \sum_{i=1}^n x_i}{n} = \bar{y} - \hat{\beta}_1 \bar{x} \\ \sum_{i=1}^n (x_i y_i - x_i \bar{y} + \hat{\beta}_1 x_i \bar{x} - \hat{\beta}_1 x_i^2) = 0 \end{cases}$$

$$\Rightarrow \begin{cases} \hat{\beta}_0 = \bar{y} - \hat{\beta}_1 \bar{x} \\ \hat{\beta}_1 = \frac{\sum_{i=1}^n (x_i y_i - x_i \bar{y})}{\sum_{i=1}^n (x_i^2 - x_i \bar{x})} \end{cases}$$

Przechylenie $\hat{\beta}_1$

$$\hat{\beta}_1 = \frac{\sum_{i=1}^n (x_i y_i - x_i \bar{y} + \bar{x} \bar{y} - y_i \bar{x})}{\sum_{i=1}^n (x_i^2 - x_i \bar{x} + \bar{x} - x_i \bar{x})}$$

$$\begin{aligned} \text{Fałt} \\ \sum_{i=1}^n (\bar{x}^2 - x_i \bar{x}) &= 0 \\ \sum_{i=1}^n (\bar{x} \bar{y} - y_i \bar{x}) &= 0 \\ \sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y}) &= \sum_{i=1}^n (x_i - \bar{x})^2 \end{aligned}$$

2.2

cel: $\hat{\beta}_1 = r \cdot \frac{s_y}{s_x}$

gdzie s_x - wariancja próbkowa x
 s_y - wariancja próbkowa y
 r - współczynnik Pearsona

$$s_y = \sqrt{\frac{1}{n} \sum_{i=1}^n (y_i - \bar{y})^2}$$

$$s_x = \sqrt{\frac{1}{n} \sum_{i=1}^n (x_i - \bar{x})^2}$$

$$r_{xy} = \frac{\sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y})}{\sqrt{\sum_{i=1}^n (x_i - \bar{x})^2} \sqrt{\sum_{i=1}^n (y_i - \bar{y})^2}}$$

korzystamy z wzoru na $\hat{\beta}_1$ z zad 1

$$\hat{\beta}_1 = \frac{\sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y})}{\sum_{i=1}^n (x_i - \bar{x})^2} = \frac{\left(\sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y}) \right) \cdot \sqrt{\sum_{i=1}^n (y_i - \bar{y})^2}}{\sqrt{\sum_{i=1}^n (x_i - \bar{x})^2} \cdot \sqrt{\sum_{i=1}^n (x_i - \bar{x})^2} \cdot \sqrt{\sum_{i=1}^n (y_i - \bar{y})^2}} =$$

$$= r \cdot \frac{\sqrt{\frac{1}{n} \sum_{i=1}^n (y_i - \bar{y})^2}}{\sqrt{\frac{1}{n} \sum_{i=1}^n (x_i - \bar{x})^2}} = r \cdot \frac{s_y}{s_x}$$

2.3

• współzmiennych dla $(x_1, e_1), \dots, (x_n, e_n)$

Jestli model regresji liniowej poprawnie opisuje zależność między x i y to $\hat{y}_i = \beta_0 + \beta_1 x_i$ $i \in N$
resydna: $e_i = y_i - \hat{y}_i$

Lineary współzmiennych korelacji $r_{xy} = \frac{\sum (x_i - \bar{x})(y_i - \bar{y})}{\sqrt{\sum (x_i - \bar{x})^2} \sqrt{\sum (y_i - \bar{y})^2}}$

Macierz na potrzeby obliczeń zastępnym T_1

$$\text{Mamy } \frac{\sum (x_i - \bar{x})(e_i - \bar{e})}{T_1} = \frac{\sum (x_i - \bar{x})(y_i - \hat{\beta}_0 - \hat{\beta}_1 x_i - \bar{e})}{T_1} \quad \left\{ \begin{array}{l} \bar{e} = \frac{\sum e_i}{n} = \\ = \frac{\sum (y_i - \hat{y}_i)}{n} = \\ = \frac{\sum (y_i - \hat{\beta}_0 - \hat{\beta}_1 x_i)}{n} = \\ = \frac{\sum y_i - n\hat{\beta}_0 - \hat{\beta}_1 \sum x_i}{n} = \frac{n\bar{y} - n\hat{\beta}_0 - \hat{\beta}_1 \sum x_i}{n} = \bar{y} - \hat{\beta}_0 - \hat{\beta}_1 \bar{x} \end{array} \right.$$

$$r = \frac{\sum x_i y_i - \hat{\beta}_0 \sum x_i - \hat{\beta}_1 \sum x_i^2 - \bar{x} \sum y_i + \hat{\beta}_0 \bar{x} \cdot n + \hat{\beta}_1 \bar{x} \sum x_i}{T_1 \bar{x} \cdot n + \hat{\beta}_1 \sum (\bar{x}^2 - \bar{x} \cdot x_i) + \sum (x_i y_i - \bar{x} y_i)} = \frac{0}{T_1} = 0$$

$$= \frac{\hat{\beta}_0 (\bar{x} \cdot n - \sum x_i) + \hat{\beta}_1 (\sum (\bar{x}^2 - \bar{x} \cdot x_i) + \sum (x_i y_i - \bar{x} y_i))}{T_1} = 0$$

$$= \frac{\sum (\frac{x_i y_i}{n} - \bar{x} \bar{y})}{T_1} = \frac{\sum (x_i y_i - \bar{x} \bar{y} \cdot n)}{T_1} = 0$$

Na wykresach
punktów
funkcyjne być
chaotyczne
restruowane
Bach korelacji

z.3

- współrzynnych dla $(\hat{y}_1, e_1), \dots, (\hat{y}_n, e_n)$

$$r = \frac{\sum (\hat{y}_i - \bar{\hat{y}})(e_i - \bar{e})}{T_2} =$$

$$= \frac{\sum (\hat{\beta}_0 + \hat{\beta}_1 x_i - \hat{\beta}_0 - \hat{\beta}_1 \bar{x})(y_i - \hat{\beta}_0 - \hat{\beta}_1 x_i)}{T_2}$$

$$= \frac{\sum \hat{\beta}_1 (x_i - \bar{x})(y_i - \hat{\beta}_0 - \hat{\beta}_1 x_i)}{T_2} \quad \text{dalej analogicznie jak dla } (x_i, e_i)$$

$$\bar{e} = 0$$

$$\bar{\hat{y}} = \frac{\sum (\hat{\beta}_0 + \hat{\beta}_1 x_i)}{n} = \hat{\beta}_0 + \hat{\beta}_1 \bar{x}$$

$$= 0$$