

Analiza szeregów czasowych

Raport 4

Jan Solarz 243889

Karol Pustelnik

22 czerwca 2021

Spis treści

1	Dopasowanie modelu ARIMA do szeregu gnp	1
1.1	Podział danych	1
1.2	Identyfikacja transformacji i modeli stacjonarnych	3
1.3	Zbadanie poprawności reszt -residua	7
1.3.1	Model średniej ruchomej - MA	7
1.3.2	Model autoregresyjny - AR	8
1.3.3	Model ARIMA	9
1.4	Porównanie modeli	11
1.5	Istotność współczynników	11
1.5.1	Model MA	11
1.5.2	Model AR	12
1.5.3	Model ARIMA	13
1.6	Wnioski	13
1.7	Konstrukcja prognoz	13
1.8	Ocena dokładności i porównanie	15
2	Porównanie dokładności prognoz dla wybranych danych	16
2.1	Podział danych	16
2.2	Dopasowanie odpowiednich modeli	17
2.3	Wyznaczenie prognoz dla modeli i przedstawienie ich	22
2.4	Porównanie dokładności	23
2.5	Wnioski dotyczące optymalnego modelu	24

Wykorzystując dane dochodu narodowego USA (dostępne w pakiecie *astsa*) *gnp* możemy do nich dopasować odpowiedni model ARIMA za pomocą przeprowadzonej pełnej diagnostyki i analizy.

1 Dopasowanie modelu ARIMA do szeregu gnp

1.1 Podział danych

Zaczynamy od podziału danych na część uczącą i testową. Dane występują z interwałem kwartalnym, część testowa ma horyzont prognozy równy 15 i odnosi się do lat 1999-2002. Prognoza dotyczy tego okresu czasu.

```

library(astsa)
library(forecast)

## Registered S3 method overwritten by 'quantmod':
##   method           from
##   as.zoo.data.frame zoo
##
## Attaching package: 'forecast'
## The following object is masked from 'package:astsa':
##
##   gas

#install.packages("itsmr")
library(itsmr) # uwaga itsmr::forecast przestania f-cję forecast z pakietu forecast!!!

##
## Attaching package: 'itsmr'
## The following object is masked from 'package:forecast':
##
##   forecast

library(lmtest)

## Loading required package: zoo
##
## Attaching package: 'zoo'
## The following objects are masked from 'package:base':
##
##   as.Date, as.Date.numeric

library(ggfortify)

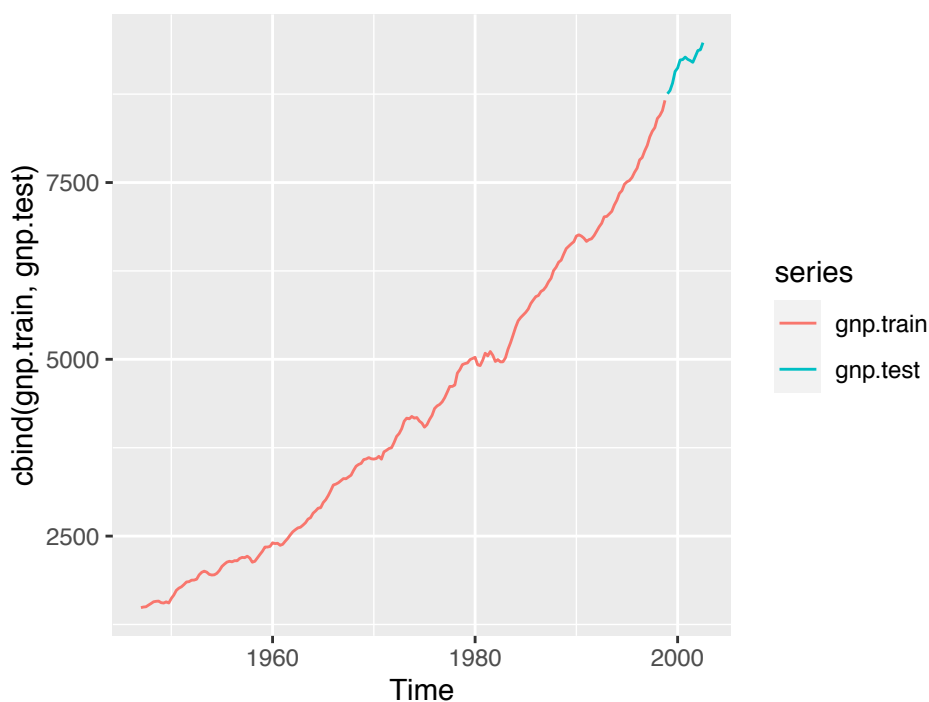
## Loading required package: ggplot2
## Registered S3 methods overwritten by 'ggfortify':
##   method           from
##   autoplot.Arima     forecast
##   autoplot.acf       forecast
##   autoplot.ar         forecast
##   autoplot.bats       forecast
##   autoplot.decomposed.ts forecast
##   autoplot.ets        forecast
##   autoplot.forecast   forecast
##   autoplot.stl        forecast
##   autoplot.ts         forecast
##   fitted.ar           forecast
##   fortify.ts          forecast
##   residuals.ar        forecast

library(stats)
library(ggplot2)
library(DescTools)

```

```
##
## Attaching package: 'DescTools'
## The following object is masked from 'package:forecast':
##
##      BoxCox

### Podział danych na część uczącą i testową
gnp.train <- window(gnp, end=c(1998,4))
gnp.test  <- window(gnp, start=c(1999,1))
autoplot(cbind(gnp.train, gnp.test))
```




```
h <- length(gnp.test) # horyzont prognozy
h
## [1] 15
```

1.2 Identyfikacja transformacji i modeli stacjonarnych

Dokonujemy różnicowania i transformacji Box-Coxa w celu otrzymania postaci stacjonarnej. Następnie identyfikujemy rzędy modeli stacjonarnych $MA(q)$, $AR(p)$ i modelu mieszanego $ARMA(p, q)$.

```
ggtsdisplay(gnp.train)
```




```
cat("Wymagana ilość różnicowań:")

## Wymagana ilość różnicowań:

ndiffs(gnp.train)

## [1] 2

ggtsdisplay(diff(gnp.train))
```



```
lambda <- BoxCox.lambda(gnp.train)
gnp.train.BC <- BoxCox(gnp.train, lambda=lambda)
cat("Wymagana ilość różnicowań po transformacji Boxa-Coxa:")

## Wymagana ilość różnicowań po transformacji Boxa-Coxa:

ndiffs(gnp.train.BC) # jaka krotność różnicowania jest potrzebna?



## [1] 1

### Wstępna identyfikacja modeli MA(q) i/lub AR(p)
gnp.train.BC.diff <- diff(gnp.train.BC)
Box.test(gnp.train.BC.diff)

##
## Box-Pierce test
##
## data: gnp.train.BC.diff
## X-squared = 22.966, df = 1, p-value = 1.649e-06
```

Po zastosowaniu na szeregu notowań transformacji Box-Coxa i jednego różnicowania otrzymujemy szereg stacjonarny.

```
ggtsdisplay(gnp.train.BC.diff)
```



```
ma13<-Arima(gnp.train, order = c(0,1,13))
ar12<-Arima(gnp.train, order = c(12,1,0))
auto.arima<-auto.arima(gnp.train)
auto.arima

## Series: gnp.train
## ARIMA(0,2,3)
##
## Coefficients:
##          ma1      ma2      ma3
##      -0.6915 -0.0624 -0.1857
## s.e.   0.0706   0.0928   0.0646
##
## sigma^2 estimated as 1378:  log likelihood=-1036.3
## AIC=2080.61  AICc=2080.81  BIC=2093.92
```

- Dla modelu $MA(q)$ funkcja autokorelacji ACF dla opóźnienia 13 posiada wartości opóźnień mniejsze od poziomu 13 mieszczące się w przedziale ufności. Stąd wynika że rząd q średniej ruchomej wynosi 13.
- Dla modelu $AR(p)$ funkcja cząstkowej korelacji PACF dla opóźnienia 12 posiada wartości opóźnień mniejsze od poziomu 12 mieszczące się w przedziale ufności. Stąd wynika że rząd p średniej ruchomej wynosi 12.
- Dla modelu $ARIMA(p, q)$ metoda krokowa wskazuje za najlepsze dopasowanie modelu $ARIMA(0, 2, 3)$ o czym świadczą najniższe kryteria informacyjne AIC, AICC, BIC.

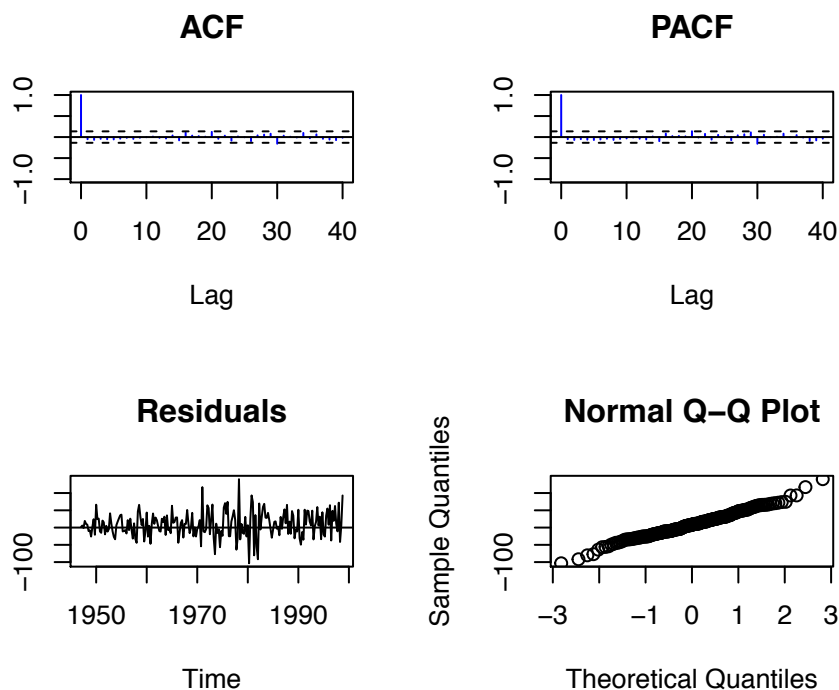
1.3 Zbadanie poprawności reszt -residua

1.3.1 Model średniej ruchomej - MA

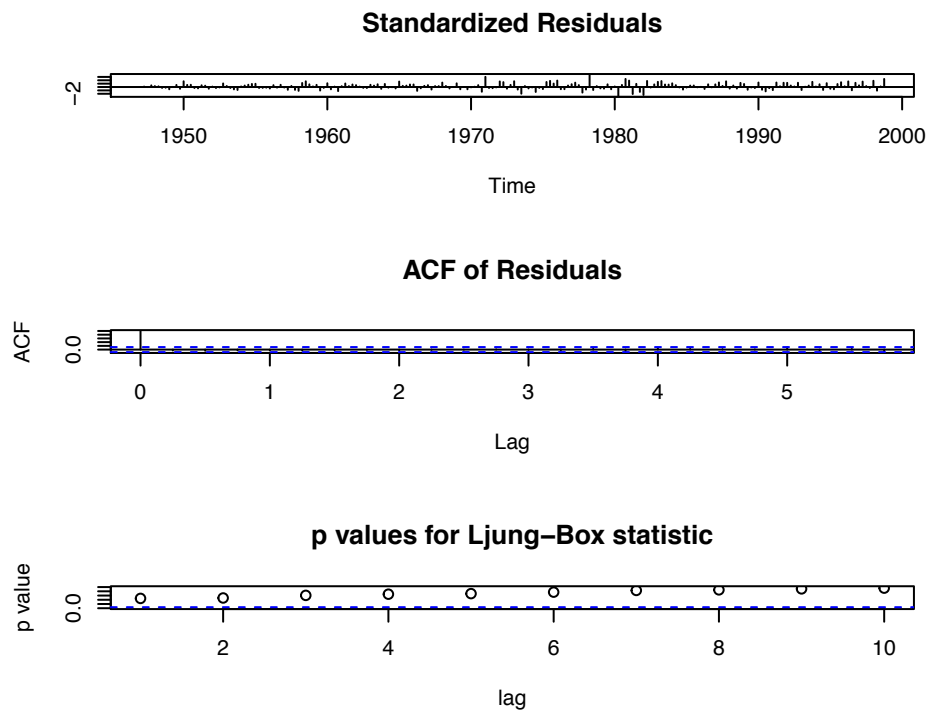
```
test(residuals(ma13))
```

```
## Null hypothesis: Residuals are iid noise.
```

## Test	Distribution	Statistic	p-value
## Ljung-Box Q	$Q \sim \text{chisq}(20)$	12.38	0.9022
## McLeod-Li Q	$Q \sim \text{chisq}(20)$	58.53	0 *
## Turning points T	$(T-137.3)/6.1 \sim N(0,1)$	142	0.4408
## Diff signs S	$(S-103.5)/4.2 \sim N(0,1)$	105	0.7193
## Rank P	$(P-10764)/501.8 \sim N(0,1)$	11501	0.1419



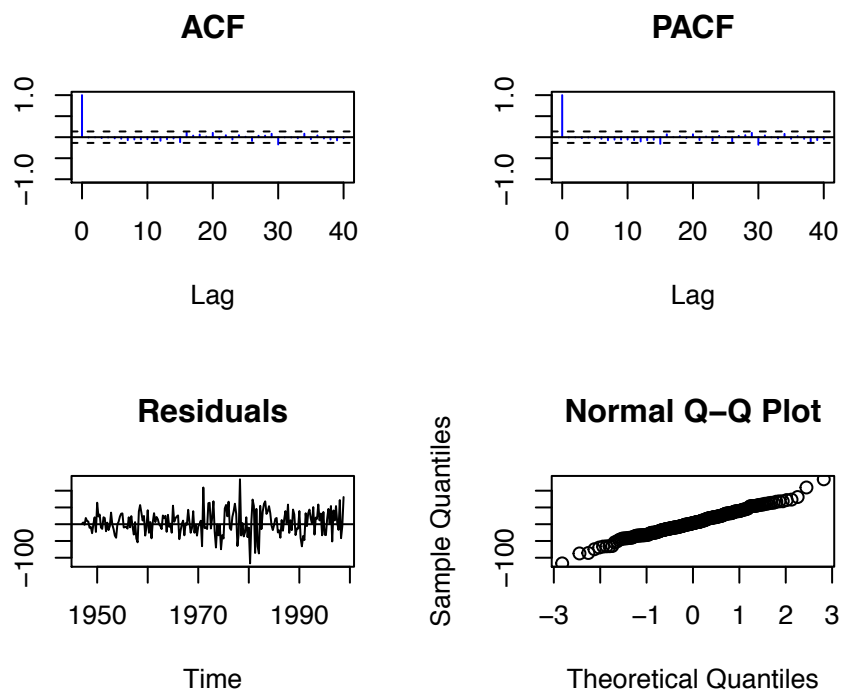
```
tsdiag(ma13)
```




1.3.2 Model autoregresyjny - AR

```
test(residuals(ar12))
```

```
## Null hypothesis: Residuals are iid noise.
## Test          Distribution Statistic  p-value
## Ljung-Box Q    Q ~ chisq(20)      16.17   0.7059
## McLeod-Li Q    Q ~ chisq(20)      73.26    0 *
## Turning points T (T-137.3)/6.1 ~ N(0,1)  146   0.1523
## Diff signs S   (S-103.5)/4.2 ~ N(0,1)  108   0.2809
## Rank P         (P-10764)/501.8 ~ N(0,1) 11157  0.4335
```

```
tsdiag(ar12)
```

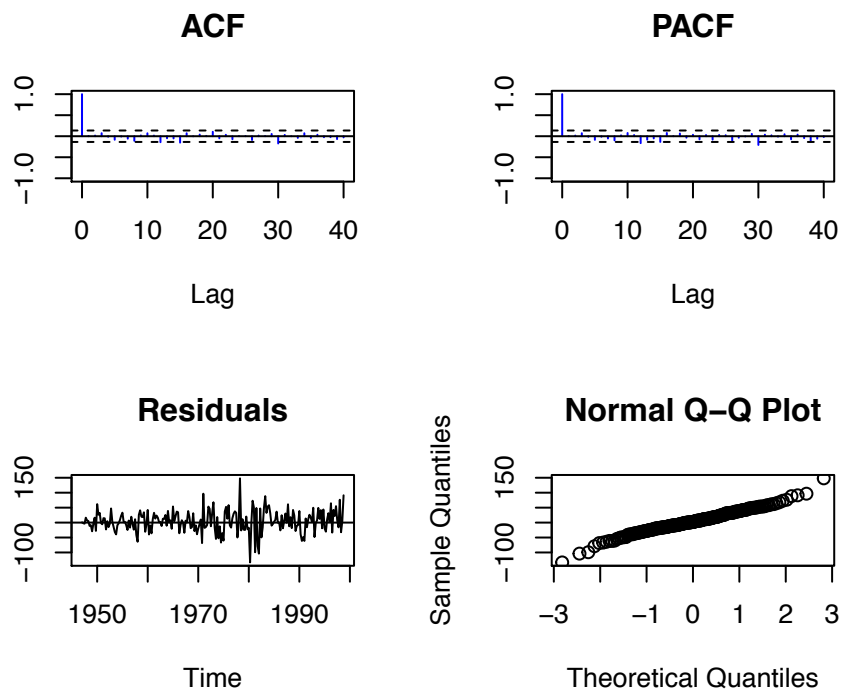


1.3.3 Model ARIMA


```
test(residuals(auto.arima))
```

```
## Null hypothesis: Residuals are iid noise.
```

## Test	Distribution	Statistic	p-value
## Ljung-Box Q	$Q \sim \text{chisq}(20)$	22.29	0.3252
## McLeod-Li Q	$Q \sim \text{chisq}(20)$	67.93	0 *
## Turning points T	$(T-137.3)/6.1 \sim N(0,1)$	141	0.5448
## Diff signs S	$(S-103.5)/4.2 \sim N(0,1)$	107	0.4017
## Rank P	$(P-10764)/501.8 \sim N(0,1)$	11254	0.3288



```
tsdiag(auto.arima)
```



Na podstawie zastosowanych testów statystycznych i metod graficznych nie mamy podstaw do odrzecenia hipotez zerowych w każdym z modeli- w każdym teście w każdej z metod p-value jest większe od 0.05. To oznacza że modele są dobrze dopasowane.

1.4 Porównanie modeli

```
cat("Kryteria informacyjne MA: ", ma13$aic,ma13$aicc, ma13$bic)

## Kryteria informacyjne MA: 2117.575 2119.762 2164.233

cat("Kryteria informacyjne AR: ", ar12$aic,ar12$aicc, ar12$bic)

## Kryteria informacyjne AR: 2106.949 2108.835 2150.274

cat("Kryteria informacyjne ARIMA: ", auto.arima$aic,auto.arima$aicc, auto.arima$bic)

## Kryteria informacyjne ARIMA: 2080.609 2080.808 2093.92
```

Kryteria wskazują jednoznacznie za najlepszą wydajność modelu ARIMA.

1.5 Istotność współczynników

1.5.1 Model MA

```
coeftest(ma13)

##
```

```
## z test of coefficients:
##
##      Estimate Std. Error z value Pr(>|z|)
## ma1  0.401110   0.069302  5.7878 7.129e-09 ***
## ma2  0.441803   0.077590  5.6941 1.241e-08 ***
## ma3  0.331102   0.081318  4.0717 4.667e-05 ***
## ma4  0.304571   0.083815  3.6338 0.0002792 ***
## ma5  0.241194   0.088992  2.7103 0.0067229 **
## ma6  0.264264   0.092647  2.8524 0.0043395 **
## ma7  0.136921   0.091421  1.4977 0.1342108
## ma8  0.115637   0.088282  1.3099 0.1902456
## ma9  0.187412   0.091269  2.0534 0.0400332 *
## ma10 0.254345   0.077400  3.2861 0.0010158 **
## ma11 0.212519   0.070894  2.9977 0.0027201 **
## ma12 0.065703   0.071839  0.9146 0.3604072
## ma13 0.129422   0.088727  1.4586 0.1446623
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

ma.fixed <- numeric(13)
ma.fixed[c(1:6,9:11)] <- NA
ma.zeros <- Arima(gnp.train, order=c(0,1,13), fixed=ma.fixed)
cat("Kryteria informacyjne MA po redukcji: ", ma.zeros$aic,ma.zeros$aicc, ma.zeros$bic)

## Kryteria informacyjne MA po redukcji:  2114.988 2116.111 2148.315
```

1.5.2 Model AR

```
coeftest(ar12)

##
## z test of coefficients:
##
##      Estimate Std. Error z value Pr(>|z|)
## ar1  0.3615396  0.0697038  5.1868 2.139e-07 ***
## ar2  0.2275594  0.0740991  3.0710 0.002133 **
## ar3  0.0557962  0.0753708  0.7403 0.459124
## ar4  0.0193596  0.0754545  0.2566 0.797508
## ar5 -0.0192326  0.0753584 -0.2552 0.798557
## ar6  0.0773832  0.0755866  1.0238 0.305944
## ar7 -0.0045655  0.0753481 -0.0606 0.951684
## ar8 -0.0351148  0.0752805 -0.4665 0.640892
## ar9  0.1335062  0.0751731  1.7760 0.075736 .
## ar10 0.1390855  0.0763465  1.8218 0.068490 .
## ar11 0.0567733  0.0761511  0.7455 0.455948
## ar12 -0.1060658 0.0713578 -1.4864 0.137175
## ---
```

```
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

ar.fixed <- numeric(12)
ar.fixed[c(1:2)] <- NA
ar.zeros <- Arima(gnp.train, order=c(12,1,0), fixed=ar.fixed)
cat("Kryteria informacyjne AR po redukcji: ", ar.zeros$aic, ar.zeros$aicc, ar.zeros$bic)

## Kryteria informacyjne AR po redukcji:  2107.804 2107.922 2117.802
```

1.5.3 Model ARIMA

```
coeftest(auto.arima)

##
## z test of coefficients:
##
##      Estimate Std. Error z value Pr(>|z|)
## ma1 -0.691464   0.070573 -9.7978 < 2.2e-16 ***
## ma2 -0.062403   0.092779 -0.6726  0.501203
## ma3 -0.185736   0.064647 -2.8731  0.004065 **
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

arima.fixed <- numeric(3)
arima.fixed[c(1,3)] <- NA
arima.zeros <- Arima(gnp.train, order=c(0,2,3), fixed=arima.fixed)
cat("Kryteria informacyjne ARIMA po redukcji: ", arima.zeros$aic, arima.zeros$aicc, arima.zeros$bic)

## Kryteria informacyjne ARIMA po redukcji:  2079.042 2079.161 2089.026
```

- Usuwamy odpowiednie współczynniki które mają odpowiednio wartości p-value mniejsze od poziomu 0.05.
- Widzimy nieznacznie polepszenie się modeli po redukcji współczynników w kryteriach informacyjnych.

1.6 Wnioski

Kryteria informacyjne jednoznacznie wskazują za najlepsze dopasowanie modelu ARIMA. Wartości p-value w testach w analizie reszt jedynie dla modelu ARIMA są zawsze większe od poziomu 0.3 co również zapewnia nas w przekonaniu że jest to najlepszy model. Model $AR(12)$ jest lepiej dopasowany od $MA(12)$ - wskazują na to kryteria informacyjne.

1.7 Konstrukcja prognoz

```

library(fma)

##
## Attaching package: 'fma'
## The following objects are masked from 'package:itsmr':
##
##      airpass, strikes
## The following objects are masked from 'package:astsa':
##
##      chicken, sales

library(forecast)
h <- length(gnp.test)
ma.forecast <- forecast::forecast(ma.zeros, h = h)
#autoplot(ma.forecast) + autolayer(gnp.test)
ar.forecast <- forecast::forecast(ar.zeros, h = h)
#autoplot(ar.forecast) + autolayer(gnp.test)

arima.forecast <- forecast::forecast(arima.zeros, h = h)
#autoplot(arima.forecast) + autolayer(gnp.test)
par(mfrow=c(2,2))
#autoplot(cbind(gnp.train, gnp.test))
autoplot(ma.forecast)+autolayer(gnp.test)

## Warning: 'filter_()' was deprecated in dplyr 0.7.0.
## Please use 'filter()' instead.
## See vignette('programming') for more help
## Error: Invalid input: date_trans works with objects of class Date only

autoplot(ar.forecast)+autolayer(gnp.test)


## Error: Invalid input: date_trans works with objects of class Date only

autoplot(arima.forecast)+autolayer(gnp.test)


## Error: Invalid input: date_trans works with objects of class Date only

```


Forecasts from ARIMA(0,1,13)



Forecasts from ARIMA(12,1,0)



Forecasts from ARIMA(0,2,3)



Widzimy, że najbardziej sensowną i zbliżoną do rzeczywistej prognozą jest ta z modelu ARIMA. Przedział ufności tutaj jest najwęższy.

1.8 Ocena dokładności i porównanie

```
accuracy(ma.forecast,gnp.test)
```

```
##                ME        RMSE        MAE        MPE        MAPE        MASE
## Training set  11.23145  37.93244  29.72248  0.2751444  0.789804  0.196597
## Test set     209.97916 239.77863 209.97916  2.2634975  2.263498  1.388891
##                ACF1 Theil's U
## Training set -0.06964959      NA
## Test set     0.65105206   3.147886
```

```
accuracy(ar.forecast,gnp.test)
```

```
##                ME        RMSE        MAE        MPE        MAPE        MASE
## Training set   8.669031  38.61327  29.43109  0.2128926  0.7868895  0.1946697
## Test set      118.892940 145.02473 123.18656  1.2791110  1.3278921  0.8148078
##                ACF1 Theil's U
## Training set -0.0811651      NA
## Test set     0.5813512   1.905563
```

```
accuracy(arima.forecast,gnp.test)
```

```
##                ME        RMSE        MAE        MPE        MAPE        MASE
## Training set   3.885223  36.71698  27.59238  0.08738656  0.7352485  0.1825076
## Test set      -39.027410 130.06256 110.77085 -0.41319888  1.1959731  0.7326851
```

```
##                      ACF1 Theil's U
## Training set 0.03419921      NA
## Test set      0.84575759    1.711471
```


Miary dokładności błędów jednoznacznie wskazują na model automatyczny typu ARIMA. Najmniej optymalnym modelem jest model MA.

2 Porównanie dokładności prognoz dla wybranych danych

2.1 Podział danych

Wybieramy jako zbiór danych miesięczną produkcję energii elektrycznej w Australii w latach 1965-1995. Jako zbiór testowy bierzemy lata 1993-1995.

```
### Podział danych na część uczącą i testową
elec.train <- window(elec, end=c(1992,12))
elec.test  <- window(elec, start=c(1993,1))
autoplot(cbind(elec.train, elec.test))
```



```
h <- length(elec.test) # horyzont prognozy
h
## [1] 32
```

2.2 Dopasowanie odpowiednich modeli


```
lambda <- BoxCox.lambda(elec.train)
elec.train.box <- BoxCox(elec.train, lambda = lambda)
ndiffs(elec.train)

## [1] 1

elec.train.diff.box <- diff(elec.train, 1)
Box.test(elec.train.diff.box)


##
## Box-Pierce test
##
## data: elec.train.diff.box
## X-squared = 2.86, df = 1, p-value = 0.09081

ggtsdisplay(elec.train.diff.box)
```



Po zastosowaniu transformacji Boxa-Coxa i różnicowaniu p-value jest większe od 0.05 więc nie mamy podstaw do odrzucenia hipotezy zerowej. Raczej mamy do czynienia z białym szumem.


```
autoplot(elec.train)
```



```
model_arima<-auto.arima(elec.train)
model_arima

## Series: elec.train
## ARIMA(0,1,1)(0,1,1)[12]
##
## Coefficients:
##          ma1      sma1
##      -0.6695 -0.5914
## s.e.   0.0383  0.0346
##
## sigma^2 estimated as 24997:  log likelihood=-2795.71
## AIC=5597.42   AICc=5597.47   BIC=5609.62

autoplot(model_arima$fitted)
```



```
library(expsmooth)

ses.alfa.optim <- ses(elec.train)$fitted
autoplot(ses.alfa.optim, main="Wygladzenie wykladnicze", lwd=.5)
```



```


# dekompozycja na podstawie modelu regresji: trend kwadratowy + sezonowość
tslm.1 <- tslm(elec.train ~ trend + season+ I(trend ^ 2),lambda = 0)
summary(tslm.1)

##
## Call:
## tslm(formula = elec.train ~ trend + season + I(trend^2), lambda = 0)
##
## Residuals:
##      Min       1Q   Median       3Q      Max
## -0.084808 -0.021988  0.000649  0.022311  0.099516
##
## Coefficients:
##              Estimate Std. Error t value Pr(>|t|)
## (Intercept)  7.107e+00  7.111e-03 999.366 < 2e-16 ***
## trend        8.052e-03  4.982e-05 161.622 < 2e-16 ***
## season2     -2.021e-02  7.804e-03  -2.589 0.009939 **
## season3      6.381e-02  7.804e-03   8.177 3.30e-15 ***
## season4      2.986e-02  7.804e-03   3.826 0.000149 ***
## season5      1.416e-01  7.804e-03  18.150 < 2e-16 ***
## season6      1.683e-01  7.804e-03  21.562 < 2e-16 ***
## season7      2.299e-01  7.804e-03  29.462 < 2e-16 ***
## season8      1.937e-01  7.804e-03  24.820 < 2e-16 ***
## season9      1.019e-01  7.804e-03  13.051 < 2e-16 ***
## season10     8.667e-02  7.805e-03  11.104 < 2e-16 ***
## season11     3.993e-02  7.805e-03   5.116 4.71e-07 ***
## season12     1.864e-02  7.805e-03   2.388 0.017364 *
## I(trend^2)   -6.422e-06  1.084e-07 -59.242 < 2e-16 ***
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Residual standard error: 0.03357 on 430 degrees of freedom
## Multiple R-squared:  0.9976, Adjusted R-squared:  0.9976
## F-statistic: 1.39e+04 on 13 and 430 DF,  p-value: < 2.2e-16

autoplot(tslm.1$fitted, main = "Dekompozycja")

```

Dekompozycja



```
Box.test(model_arima$fitted)

##
## Box-Pierce test
##
## data:  model_arima$fitted
## X-squared = 434.48, df = 1, p-value < 2.2e-16

Box.test(ses.alfa.optim)

##
## Box-Pierce test
##
## data:  ses.alfa.optim
## X-squared = 433.86, df = 1, p-value < 2.2e-16

Box.test(tslm.1$fitted.values)

##
## Box-Pierce test
##
## data:  tslm.1$fitted.values
## X-squared = 433.74, df = 1, p-value < 2.2e-16
```

- Tworzymy model typu arima rzędu (0,1,1)
- Następnie korzystamy z algorytmu wygładzania wykładniczego przy optymalnym doborze parametru alfa

- Ostatni model bazuje na dekompozycji na podstawie modelu regresji uwzględniającym trend kwadratowy i sezonowość.
- Wartości testów statystycznych poświadczają sens modeli

2.3 Wyznaczenie prognoz dla modeli i przedstawienie ich

Na podstawie skonstruowanych modeli dokonujemy prognozy na zbiorze testowym. Budujemy również oparty na naiwnej metodzie prognozy (błądzenie losowe) w celu rzetelnego porównania.

```
h <- length(elec.test)
#model.naive<-snaive(elec.train)
arima.forecast <- forecast::forecast(model_arima, h = h)
ses.forecast <- forecast::forecast(ses.alfa.optim, h = h)
tslm.forecast <- forecast::forecast(tslm.1, h = h)
naive.forecast<-snaive(elec.train)
#autoplot(arima.forecast) +autolayer(gnp.test)
par(mfrow=c(2,2))
#autoplot(cbind(gnp.train,gnp.test))
autoplot(arima.forecast)+autolayer(elec.test)


## Error: Invalid input: date_trans works with objects of class Date only
autoplot(ses.forecast)+autolayer(elec.test)

## Error: Invalid input: date_trans works with objects of class Date only
autoplot(tslm.forecast)+autolayer(elec.test)

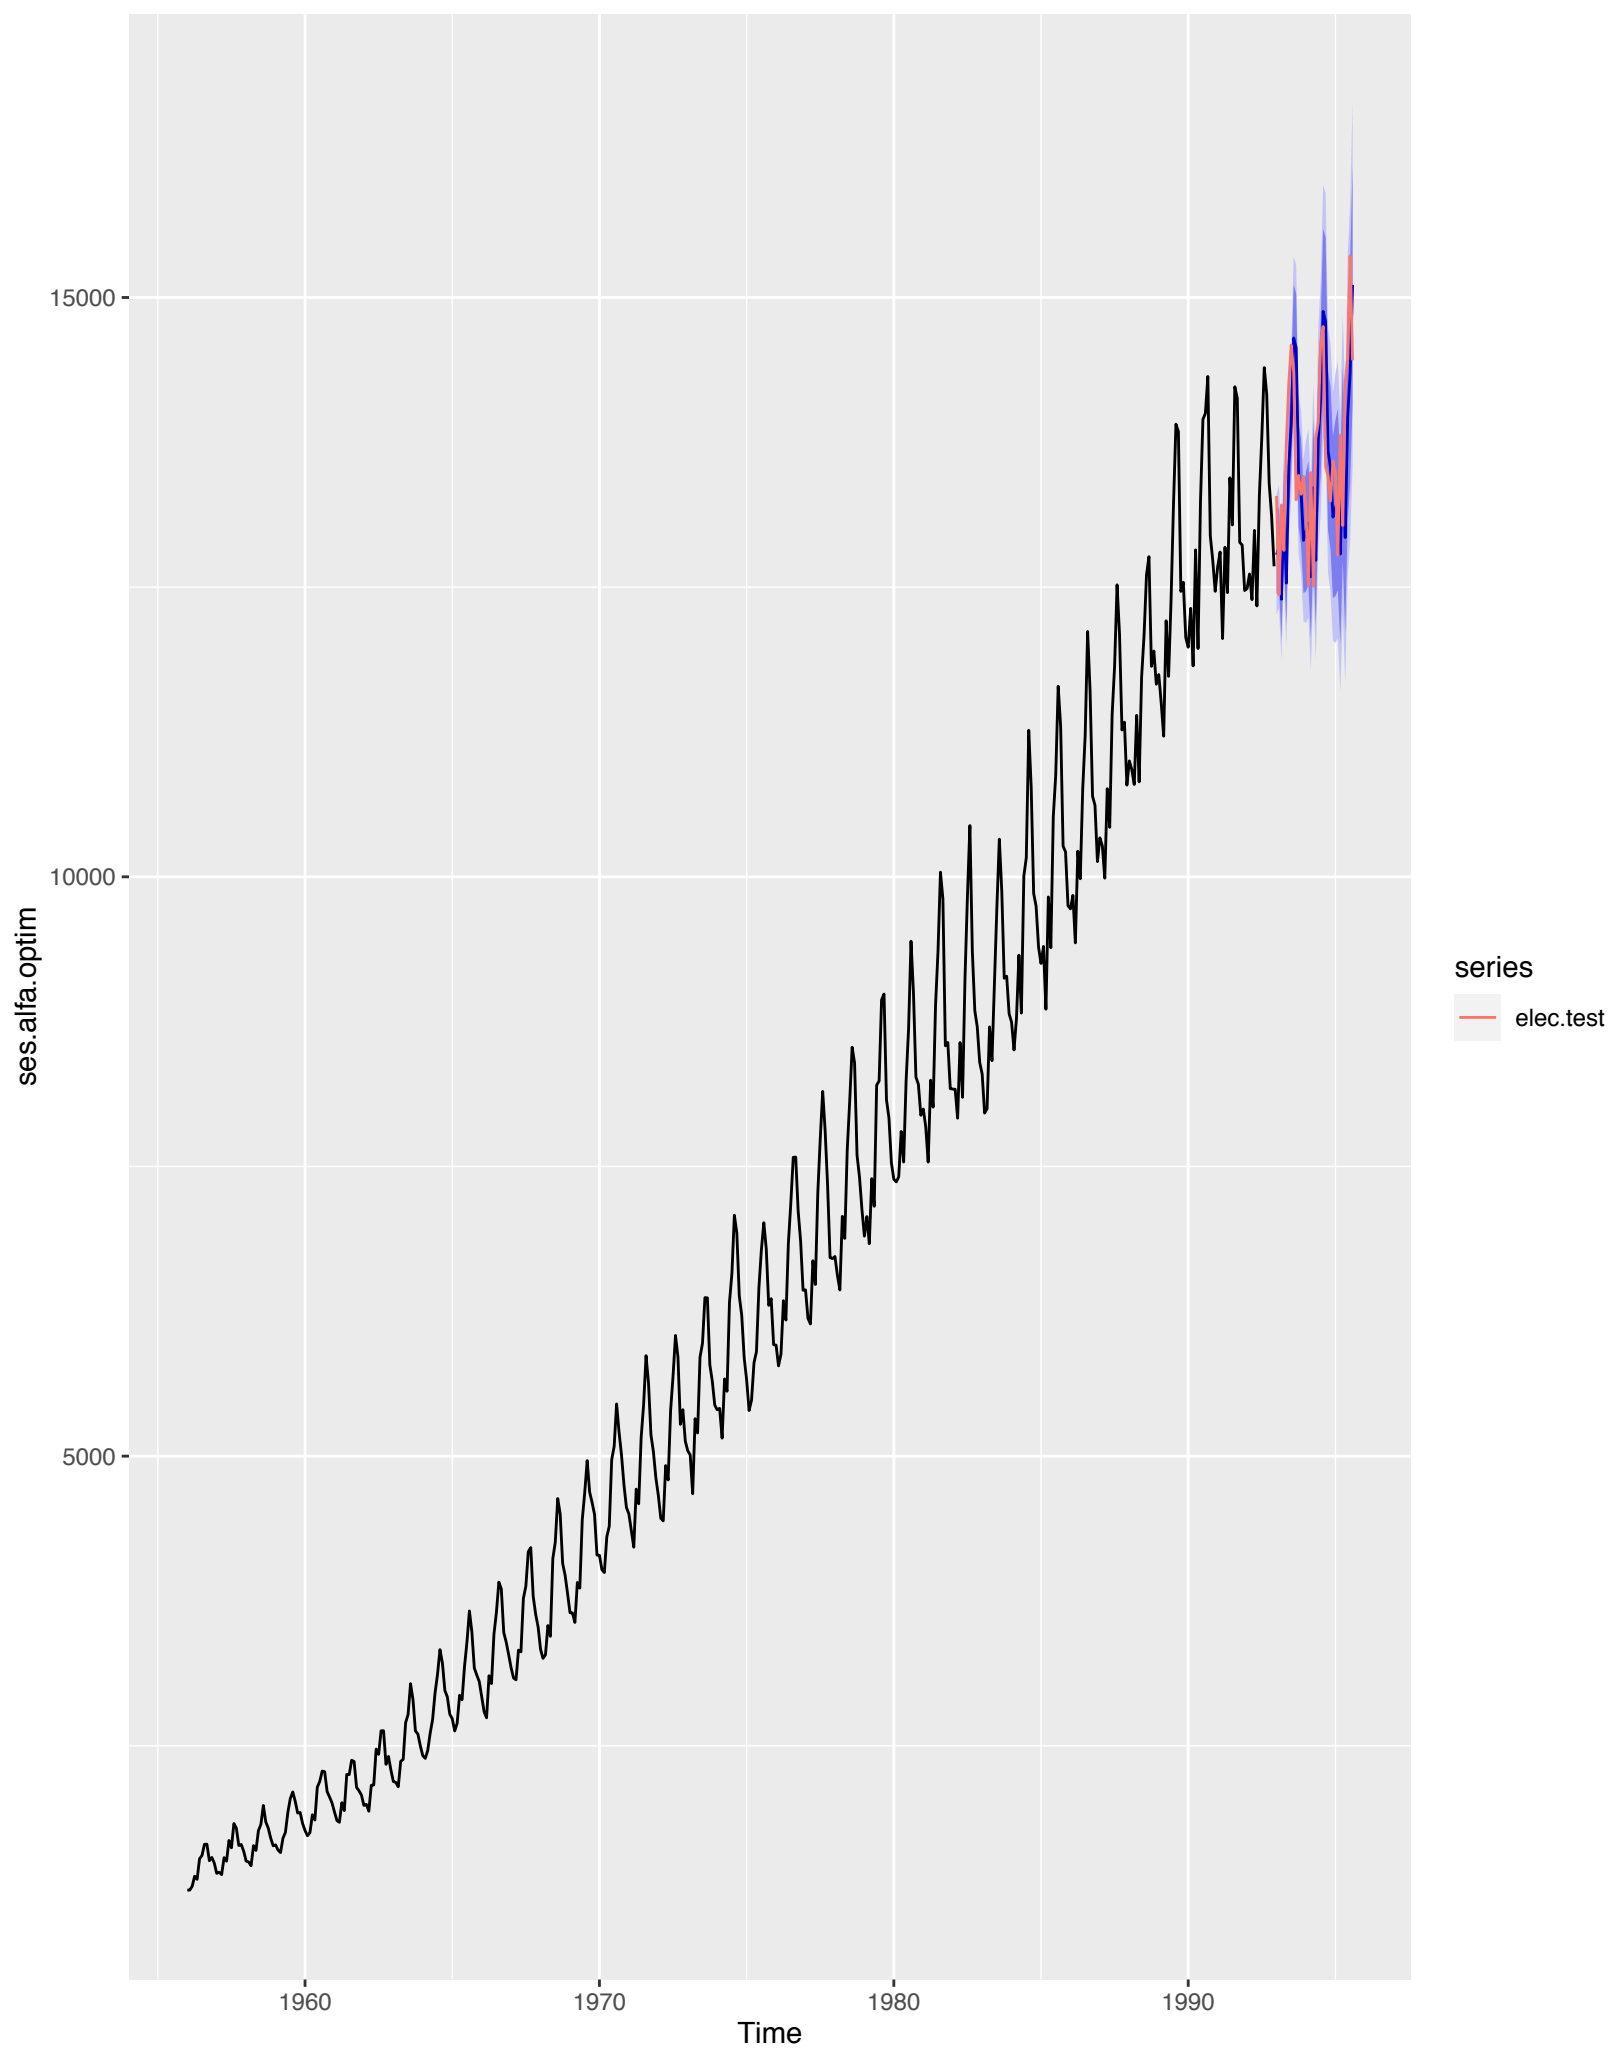
## Error: Invalid input: date_trans works with objects of class Date only
autoplot(naive.forecast)+autolayer(elec.test)

## Error: Invalid input: date_trans works with objects of class Date only
```


Forecasts from ARIMA(0,1,1)(0,1,1)[12]




Forecasts from ETS(M,A,M)



Forecasts from Linear regression model



Forecasts from Linear regression model



2.4 Porównanie dokładności

```
accuracy(model_arima$fitted,elec.train)

##              ME      RMSE      MAE      MPE      MAPE      ACF1 Theil's U
## Test set  1.637699 155.4112 108.4411 0.01632185 1.780561 0.007556606 0.3618897

accuracy(ses.alfa.optim,elec.train)

##              ME      RMSE      MAE      MPE      MAPE      ACF1 Theil's U
## Test set 26.61184 434.91 314.1734 0.3452704 4.943721 -0.01574756 1.001061

accuracy(tslm.1$fitted.values,elec.train)

##              ME      RMSE      MAE      MPE      MAPE      ACF1 Theil's U
## Test set 0.07994717 252.8728 171.3304 -0.05458318 2.650288 0.7352673 0.5224678

accuracy(snaive(elec)$fitted,elec.train)

##              ME      RMSE      MAE      MPE      MAPE      ACF1 Theil's U
## Test set 324.1343 400.173 340.2546 5.863179 6.020125 0.5331916 1.052554

accuracy(arima.forecast,elec.test)

##              ME      RMSE      MAE      MPE      MAPE      MASE
## Training set  1.637699 155.4112 108.4411 0.01632185 1.780561 0.3187057
## Test set      103.670086 259.1988 199.3885 0.76316590 1.459976 0.5859979
##              ACF1 Theil's U
## Training set 0.007556606      NA
## Test set      0.227134774 0.3442258
```

```
accuracy(ses.forecast,elec.test)
```

```
##              ME      RMSE      MAE      MPE      MAPE      MASE
## Training set -1.267708 150.0385  97.41191 0.05527837 1.537711 0.2871615
## Test set     143.586378 708.4009 601.32984 0.93440461 4.401336 1.7726660
##              ACF1 Theil's U
## Training set  0.2160129      NA
## Test set      -0.2096247  1.002657
```

```
accuracy(tslm.forecast,elec.test)
```

```
##              ME      RMSE      MAE      MPE      MAPE MASE      ACF1
## Training set      Inf      Inf      Inf      NaN      NaN  NaN      NA
## Test set         -367.2003 733.272 601.5153 -2.544548 4.314066  NaN 0.7066701
##              Theil's U
## Training set      NA
## Test set          0.9752321
```

```
accuracy(naive.forecast,elec.test)
```

```
##              ME      RMSE      MAE      MPE      MAPE      MASE      ACF1
## Training set 324.1343 400.1730 340.2546 5.863179 6.020125 1.000000 0.5331916
## Test set     397.0000 491.4618 405.4167 2.932716 2.996219 1.19151 0.1873200
##              Theil's U
## Training set      NA
## Test set          0.7219367
```

Opierając się głównie na najbardziej odpowiedniej miarze MASE widać że zdecydowanie najlepsze dopasowanie ma model ARIMA. Reszta typów miar podobnie wskazuje.

2.5 Wnioski dotyczące optymalnego modelu

Wszystkie testy i miary dokładności błędów jednomyślnie wskazują że najbardziej optymalnym modelem jest model typu ARIMA. Najgorszy wydaje się być model demopozycji, istnieje tutaj problem z miarami. Model oparty na algorytmie wygładzania wykładniczego również posiada dokładność na przyzwoitym poziomie- miary są niższe niż przy modelu naiwnym.